



Modelos de Difusión Generativa

Procesamiento Digital de Imágenes

Prof. Lucas Miguel Iturriago Salas

Universidad Nacional de Colombia
Departamento de Ingeniería Eléctrica, Electrónica y Computación

Primer Semestre - 2026

Intuición Fundamental

Los modelos de difusión generan datos de alta fidelidad mediante el modelado de un proceso bidireccional:

- **Proceso Directo (Ida):** Destrucción sistemática de la estructura de la imagen mediante la adición controlada de ruido gaussiano.
- **Proceso Inverso (Vuelta):** Reversión analítica de la destrucción guiada por una red neuronal profunda que estima las perturbaciones.

1. El Proceso Directo (Forward Process / q)



La transición paso a paso se define como una cadena de Markov que inyecta ruido según un cronograma de varianza (*variance schedule*) $\beta_t \in (0, 1)$:

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t}x_{t-1}, \beta_t \mathbf{I})$$

Propiedades Matemáticas Clave

- **Conservación de la Varianza (1):** Los coeficientes $\sqrt{1 - \beta_t}$ (atenuación de la señal) y β_t (escala del ruido) garantizan mediante sus cuadrados que la potencia total del tensor se mantenga tipificada en 1: $(\sqrt{1 - \beta_t})^2 + \beta_t = 1$.
- **Matriz Identidad (I):** Modela estadísticamente la independencia estocástica pixel a pixel en la vectorización latente.

1.1. Muestreo Directo en un Paso Arbitrario (Teletransportación)

Definiendo $\alpha_t = 1 - \beta_t$ y el producto acumulado $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$, el truco de reparametrización permite saltar directamente desde x_0 a un tiempo t sin iterar el bucle:

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon \quad \text{donde} \quad \epsilon \sim \mathcal{N}(0, \mathbf{I})$$

Dinámica de los Coeficientes ($t \rightarrow T$)

- Al avanzar el tiempo, el remanente de la señal original decrece ($\bar{\alpha}_t \rightarrow 0$).
- La varianza asignada al ruido acumulado domina la varianza total ($1 - \bar{\alpha}_t \rightarrow 1$).
- En el límite $t = T$, la estructura inicial colapsa hacia ruido blanco puro.

2. El Proceso Inverso (Reverse Process / p_θ)

La distribución condicional real $q(x_{t-1}|x_t)$ es estadísticamente **intratable**, dado que requeriría integrar sobre toda la distribución real de los datos marginales.

Solución Numérica

Aproximamos la distribución mediante una parametrización por red neuronal de pesos θ :

$$p_\theta(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t))$$

- Estabilizar el entrenamiento requiere mantener la escala unificada (Varianza = 1) a lo largo del flujo temporal.
- Capas tradicionales como *BatchNorm* fallan al promediar dinámicas temporales del batch; se sustituyen por **Group Normalization (GroupNorm)**.

2.1. El Atajo: Predicción del Ruido vs. Predicción de la Media



Predecir la estructura limpia μ_θ directamente provoca distribuciones sobre-suavizadas (imágenes borrosas). Mediante el Teorema de Bayes, la media teórica se reformula en función del ruido ϵ :

$$\mu = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon \right)$$

Estrategia de Entrenamiento

Se entrena el aproximador óptimo (normalmente una **U-Net híbrida / Diffusion Transformer**) para estimar únicamente el ruido inyectado, $\epsilon_\theta(x_t, t)$, delegando el cálculo de la media a la expresión analítica directa.

2.2. Algoritmo de Muestreo (Denoising Sampling)

Una vez calibrado el estimador $\epsilon_\theta(x_t, t)$, el paso de inferencia iterativo se ejecuta mediante la ecuación estocástica de diferencias:

$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(x_t, t) \right) + \sigma_t z \quad \text{donde} \quad z \sim \mathcal{N}(0, \mathbf{I})$$

¿Por qué la fracción $\frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}}$ en lugar de solo $\sqrt{\beta_t}$?

Es un **factor de escala estocástico** debido al desfase de objetivos:

- El modelo matemático ideal exige restar el ruido de **un solo paso** (varianza β_t).
- Sin embargo, la U-Net ϵ_θ fue entrenada para predecir el **ruido acumulado total** de la teletransportación (cuya desviación estándar es $\sqrt{1 - \bar{\alpha}_t}$).
- **El Cociente:** Al dividir $\frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}}$, se "normaliza" la predicción global de la red, convirtiéndola en la proporción exacta de ruido que corresponde remover en este paso individual.

2.2. Algoritmo de Muestreo (Denoising Sampling)

Desglose de Componentes

- **Sustracción Escalada del Ruido:** Remoción del vector de perturbación calibrado al instante t .
- **Escalamiento Inverso** ($\frac{1}{\sqrt{\alpha_t}}$): Restaura la amplitud de la señal limpia.
- **Inyección Creativa** ($\sigma_t z$): Mantiene la diversidad estocástica en cada paso.

3. Classifier-Free Guidance (CFG)

Para condicionar semánticamente la trayectoria en el espacio latente y forzar la fidelidad al prompt de texto, se calcula la predicción del ruido bajo dos condiciones en paralelo dentro del bucle:

- 1 **Predicción Condicionada (ϵ_c)**: Inyección del embedding de texto vía mecanismos de atención cruzada (*Cross-Attention*).
- 2 **Predicción No Condicionada ($\epsilon_\emptyset$)**: Evaluación con prompt vacío (contexto nulo).

Extrapolación Vectorial de la Guía

$$\epsilon_{\text{final}} = \epsilon_\emptyset + s \cdot (\epsilon_c - \epsilon_\emptyset)$$

Donde la diferencia ($\epsilon_c - \epsilon_\emptyset$) aísla el vector de características semánticas específicas del prompt. El hiperparámetro de escala s amplifica esta señal dirigida.

Espacios de Alineación Multimodal (CLIP)

El condicionamiento efectivo requiere la proyección de texto y matrices visuales a un espacio latente común donde los vectores descriptivos y sus contrapartes geométricas guardan alta similitud de coseno.

Mecanismo Interno de los Bloques de Atención Cruzada

La red neuronal opera transformaciones algebraicas lineales internas (*Query*, *Key*, *Value*) para computar el mapeo contextual:

- **Q** (Queries) $\leftarrow$ Proyecciones de las características del mapa latente de la imagen.
- **K, V** (Keys/Values) $\leftarrow$ Proyecciones del embedding de tokens de texto.

4. Modificaciones Avanzadas: Image-to-Image

La técnica de *Img2Img* rompe la inicialización desde ruido blanco puro, restringiendo el espacio de búsqueda semántico a partir de una geometría de referencia x_0 .

Pipeline Teórico del Proceso

- 1 **Codificación Latente:** Mapeo al espacio latente compacto: $z_0 = \mathcal{E}(x_0)$.
- 2 **Inyección Parcial de Ruido:** Teletransportación directa hasta un tiempo de corte indexado por el parámetro *Strength* ($S \in [0, 1]$):

$$t_{\text{start}} = \text{int}(S \cdot T)$$

$$z_{t_{\text{start}}} = \sqrt{\bar{\alpha}_{t_{\text{start}}}} z_0 + \sqrt{1 - \bar{\alpha}_{t_{\text{start}}}} \epsilon$$

- 3 **Inferencia Acortada:** Ejecución del bucle inverso exclusivamente en el intervalo de tiempo $[t_{\text{start}}, 0]$.

4.1. Análisis del Hiperparámetro Strength (S)

El valor escalar de S actúa como el modulador de la varianza inicial del proceso inverso, controlando el balance entre rigidez estructural y libertad semántica:

Configuración	Estado Estocástico Inicial	Efecto en el Output
$S \rightarrow 0$	$t_{\text{start}} \rightarrow 0$ (Baja inyección de ruido)	Salida idéntica al target original.
$S \sim 0,5$	Equilibrio de varianzas retenidas	Conserva siluetas; añade texturas.
$S \rightarrow 1$	$t_{\text{start}} \rightarrow T$ (Destrucción total)	Equivale a Text-to-Image puro.

Conclusión Concluyente

S determina analíticamente cuántos pasos intermedios de reversión ejecutará la U-Net/DiT. Menos pasos limitan el acoplamiento del prompt de texto; más pasos eliminan la topología original de la imagen guía.